ProyectoTD2026

Tratamiento de los Datos. Grado en Ciencia de Datos- UV

GrupoH

2026-05-12

Contents

1 Introduccion **2**

1.1 Contexto del proyecto 2

1.2 Preguntas de investigación 2

2 Metodología y Preparación de Datos **3**

2.1 Importación y estandarización 3

2.2 Gestión temporal e Ingeniería de variables 3

2.3 Limpieza, tipado y filtrado 3

3 Análisis y visualización de datos. **4**

3.1 Análisis Estructural y Diccionario de Datos 4

3.2 Exploración Univariante: Distribución de la actividad general 4

3.3 Detección y análisis de valores atípicos (Outliers) 5

4 Resultados: Respuesta a las Preguntas de Investigación **10**

4.1 ¿ En qué días de la semana hay más picos de actividad? 10

4.2 ¿Cuáles son las horas a las que prefieren estudiar los alumnos de Tratamiento de datos? . . . 11

4.3 ¿Es posible identificar y agrupar a los alumnos en distintos "perfiles de estudiante" (ej. constantes, de última hora, inactivos) según sus patrones de uso del Aula Virtual? 13

4.4 ¿Con cuánta antelación entregan el Miniproyecto los alumnos? 14

4.5 ¿Existe una diferencia significativa en la actividad de los alumnos entre los días laborables y los fines de semana o festivos? 14

4.6 ¿Qué porcentaje de la actividad se realiza en la ETSE y qué porcentaje se realiza fuera de esta? 16

4.7 ¿Hay más actividad provocada por las tareas o se produce más para revisar los apuntes de cada tema? 16

5 Conclusiones **16**

Simple Summary: Este proyecto analiza cómo los estudiantes de Ciencia de Datos interactúan con el Aula Virtual en la asignatura "Tratamiento de Datos". Al estudiar su rastro digital (clics), hemos identificado los horarios preferidos de estudio, si los alumnos dejan las tareas para el último momento y si prefieren trabajar desde el campus o desde casa. El objetivo final es proporcionar a los profesores una herramienta visual que les ayude a entender mejor las necesidades del grupo y mejorar la organización de la asignatura.

Abstract: En el marco de la Analítica del Aprendizaje (Learning Analytics), este trabajo presenta un flujo de trabajo completo en R para el análisis de los registros de actividad (logs) de Moodle durante el curso 2024-2025. La metodología incluye el preprocesamiento de datos con tidyverse, la gestión temporal con lubridate y la detección de valores atípicos (outliers) mediante el método del Rango Intercuartílico (IQR). Los resultados revelan una marcada tendencia a la procrastinación en las entregas del Miniproyecto y una diferencia estadística significativa entre la actividad en días lectivos y festivos. El análisis permite segmentar perfiles de estudiantes (constantes vs. de último minuto) y demuestra que la minería de datos educativos es fundamental para la intervención pedagógica temprana.

Palabras clave: Análisis, Moodle, R, limpieza de datos, Tratamiento de Datos.

1 Introduccion

1.1 Contexto del proyecto

La digitalización de la enseñanza superior ha transformado las plataformas de aprendizaje virtual, como Moodle, en fuentes masivas de datos. Cada interacción de un estudiante genera un registro que, analizado correctamente, puede revelar patrones de comportamiento invisibles a simple vista.

Este proyecto surge de la necesidad de aplicar técnicas de Ciencia de Datos sobre el conjunto de registros de la asignatura "Tratamiento de Datos" de la Universitat de València. El propósito no es solo limpiar y organizar la información, sino realizar un Análisis Exploratorio de Datos (AED) profundo que nos permita comprender la dinámica del curso durante el segundo cuatrimestre.

1.2 Preguntas de investigación

Para alcanzar el objetivo establecido, el trabajo se estructura en torno a la resolución de las siguientes preguntas de investigación:

- ¿En qué días de la semana y franjas horarias se concentran los mayores picos de actividad de los alumnos?
- ¿Es posible identificar y agrupar a los alumnos en distintos "perfiles de estudiante" (ej. constantes, de última hora, inactivos) según sus patrones de uso del Aula Virtual?
- ¿Con cuánta antelación entregan el Miniproyecto los alumnos?
- ¿Existe una diferencia significativa en la actividad de los alumnos entre los días laborables y los fines de semana o festivos?
- ¿Qué porcentaje de la actividad se realiza en la ETSE y qué porcentaje se realiza fuera de esta?
- ¿Hay más actividad provocada por las tareas o se produce más para revisar los apuntes de cada tema?

2 Metodología y Preparación de Datos

La fase de preparación de datos es la etapa crítica de este proyecto, para garantizar la calidad, consistencia y fiabilidad de los resultados. En esta sección se detalla el proceso de ingesta, limpieza y transformación del conjunto de datos original (`logs_moodle_anon.csv`), adaptándolo para el Análisis Exploratorio de Datos.

Para llevar a cabo este procesamiento, se ha utilizado el entorno de programación R, empleando la colección de paquetes `tidyverse` para la manipulación eficiente de *dataframes* y la librería `lubridate` para el tratamiento avanzado de series temporales.

El flujo de trabajo aplicado consta de las siguientes fases metodológicas:

2.1 Importación y estandarización

En primer lugar, se procede a la carga del archivo original. Las bases de datos provenientes de sistemas como Moodle suelen contener nombres de columnas con espacios y caracteres especiales. Para facilitar el manejo programático y mantener un código limpio, se han renombrado estas variables bajo un estándar consistente (por ejemplo, transformando "Nombre completo del usuario" a `usuario` y "Contexto del evento" a `contexto`).

2.2 Gestión temporal e Ingeniería de variables

Dado que gran parte de nuestras preguntas de investigación tienen un carácter cronológico, la variable original de tiempo se ha convertido al formato estándar de fecha y hora (`POSIXct`) mediante la función `dmy_hms()`. A partir de esta marca temporal, se han extraído e ingeniado nuevas características (*feature engineering*) que serán fundamentales para el análisis: la fecha exacta (`fecha`), la hora del día (`hora`), el día de la semana (`dia_semana`) y el mes (`mes`).

2.3 Limpieza, tipado y filtrado

Para delimitar el alcance del estudio al periodo lectivo correspondiente, se ha aplicado un filtro para conservar exclusivamente los registros del cuatrimestre activo (del 1 de enero al 31 de julio de 2025).

Además, se ha realizado una conversión de tipos de datos (*Type casting*), transformando las variables de naturaleza categórica a formato *factor*. Esta operación no solo optimiza el uso de la memoria, sino que es un requisito indispensable para la correcta generación de gráficos y la aplicación de métodos estadísticos. Finalmente, para asegurar la integridad de la información, se han eliminado los posibles registros duplicados del sistema, obteniendo así nuestro conjunto de datos final y limpio.

```
## # A tibble: 6 x 13
##   fecha_hora          usuario usuario_afectado contexto        componente evento
##   <dttm>              <fct>   <fct>            <fct>           <fct>      <fct>
## 1 2025-07-17 16:19:19 U0027   <NA>             Curso: 2024-25~ Sistema    Curso~
## 2 2025-07-17 16:19:09 U0027   <NA>             Foro: Noticias  Foro       Tema ~
## 3 2025-07-16 19:11:11 U0022   <NA>             Curso: 2024-25~ Sistema    Curso~
## 4 2025-07-16 19:10:38 U0022   U0022            Curso: 2024-25~ Usuario    Infor~
## 5 2025-07-16 19:10:34 U0022   <NA>             Curso: 2024-25~ Sistema    Curso~
## 6 2025-07-16 11:40:10 U0110   <NA>             Curso: 2024-25~ Sistema    Curso~
## # i 7 more variables: descripcion <chr>, origen <fct>, ip <chr>, fecha <date>,
## #   hora <int>, dia_semana <ord>, mes <ord>
```

Table 1: Resumen estructural del conjunto de datos.

Métrica	Valor
Total de registros (limpios)	107105
Usuarios únicos	83
Tipos de eventos distintos	106
Componentes distintos	25

Table 2: Diccionario de datos final tras el proceso de ingeniería de variables.

Variable	Tipo	Descripción
fecha_hora	POSIXct (datetime)	Marca de tiempo completa (fecha y hora).
usuario	Factor	Identificador único del usuario (anonimizado).
usuario_afectado	Factor	Usuario sobre el que recae la acción (si aplica).
contexto	Factor	Entorno o curso donde ocurre el evento.
componente	Factor	Módulo de Moodle (Tarea, Foro, Sistema, etc.).
evento	Factor	Acción específica realizada por el usuario.
descripcion	Character	Descripción detallada de la interacción.
origen	Factor	Plataforma de acceso (web o móvil).
ip	Character	Dirección de red del dispositivo (IPv4/IPv6).
fecha	Date	Fecha del evento (YYYY-MM-DD).
hora	Integer	Hora del día en formato 24h (0-23).
dia_semana	Ordered Factor	Día de la semana (Lunes-Domingo).
mes	Ordered Factor	Mes del año (Enero-Diciembre).

3 Análisis y visualización de datos.

El Análisis Exploratorio de Datos constituye la fase central de nuestro estudio. En esta etapa, aplicamos técnicas estadísticas y de visualización para descubrir patrones, comprender la distribución de la actividad en el Aula Virtual y asentar las bases antes de responder a las preguntas de investigación.

3.1 Análisis Estructural y Diccionario de Datos

Tras ejecutar el proceso de limpieza y la creación de nuevas variables temporales (*Feature Engineering*), el conjunto de datos definitivo (`logs`) se compone de **107.105 observaciones** y **13 variables**. Este volumen de registros limpios representa el núcleo de nuestro análisis.

A continuación, en la Tabla 1 se exponen las métricas generales que dimensionan el ecosistema de la asignatura, mostrando la cantidad de alumnos implicados y la diversidad de acciones que pueden realizar.

Para garantizar la reproducibilidad y la correcta interpretación de los análisis posteriores, es indispensable documentar el estado final de las características del dataframe. El Diccionario de Datos resultante, donde se especifican los tipos (como Factor o POSIXct), se presenta en la Tabla 2.

3.2 Exploración Univariante: Distribución de la actividad general

Una vez validada la integridad y estructura de la información, procedemos a examinar cómo se distribuyen de forma general estos registros. Comprender en qué momentos del día interactúan los alumnos con la plataforma es vital para establecer el ritmo base de la asignatura.

Como ejemplo principal de esta exploración univariante, la Figura 1 ilustra la frecuencia de los accesos e interacciones a lo largo de las distintas horas del día. Esta visualización nos permite identificar de un vistazo las franjas de mayor rendimiento y los periodos de inactividad nocturna.

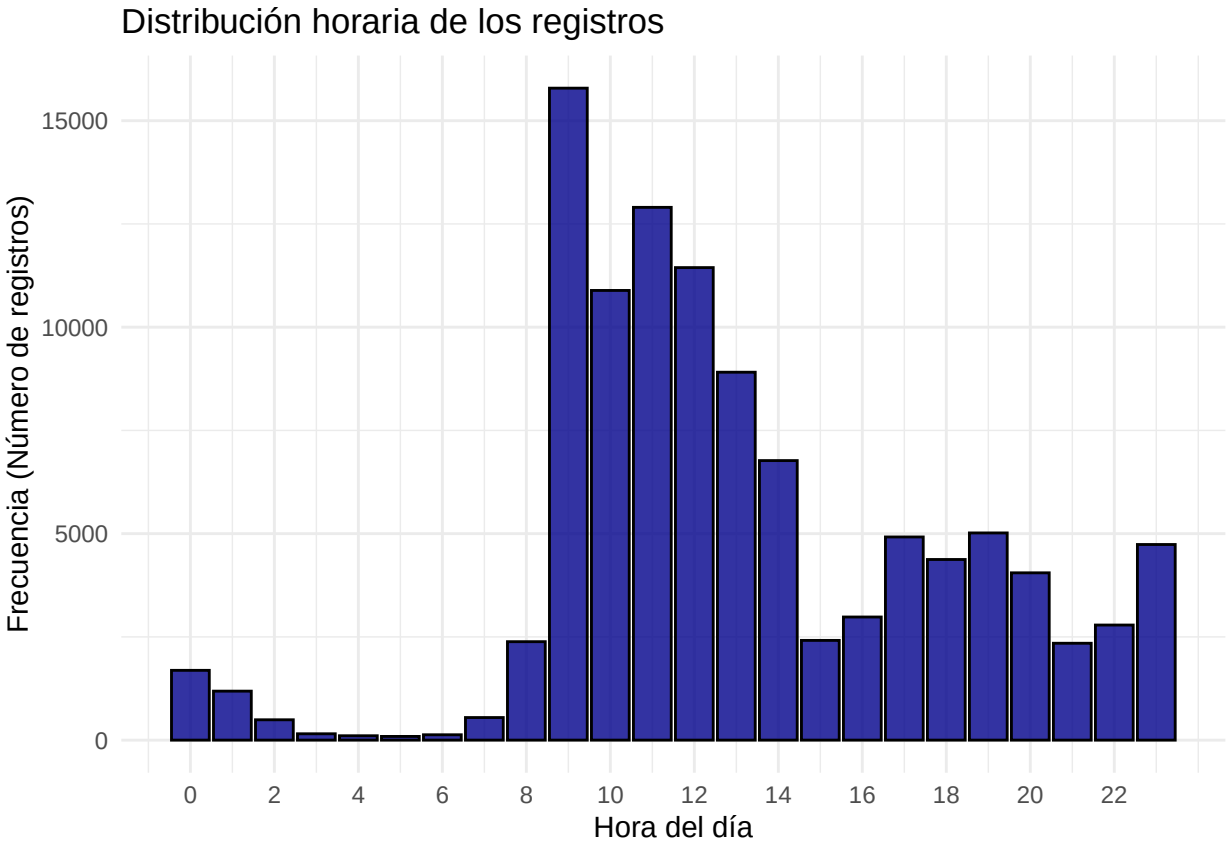

Figure 1: Distribución horaria de los registros

3.3 Detección y análisis de valores atípicos (Outliers)

Cuando analizamos los datos del Aula Virtual, nos damos cuenta de que no todos los alumnos usan la plataforma de la misma manera. Mientras que la mayoría mantiene un ritmo de trabajo parecido, siempre hay estudiantes que interactúan muchísimo más de lo normal, o por el contrario, muy por debajo de la media.

Para identificar matemáticamente a estos estudiantes con comportamientos extremos, hemos sumado el número total de interacciones (clics) que ha hecho cada alumno durante el cuatrimestre y hemos aplicado el método estadístico del Rango Intercuartílico (IQR).

Este método nos permite calcular unos límites matemáticos para definir qué es un comportamiento normal y qué se sale de lo común. En base a esto, hemos clasificado a los estudiantes en tres perfiles:

Hiperactivos: Aquellos que superan el límite superior, es decir, interactúan con la plataforma mucho más que el resto de la clase.

Inactivos extremos: Aquellos que se quedan por debajo del límite inferior.

Normales: El estandar de la clase, que se mueve dentro de los límites esperados.

La Figura 2 muestra la distribución de la actividad por estudiante mediante un diagrama de caja (boxplot), acompañado de los puntos individuales correspondientes a cada usuario.

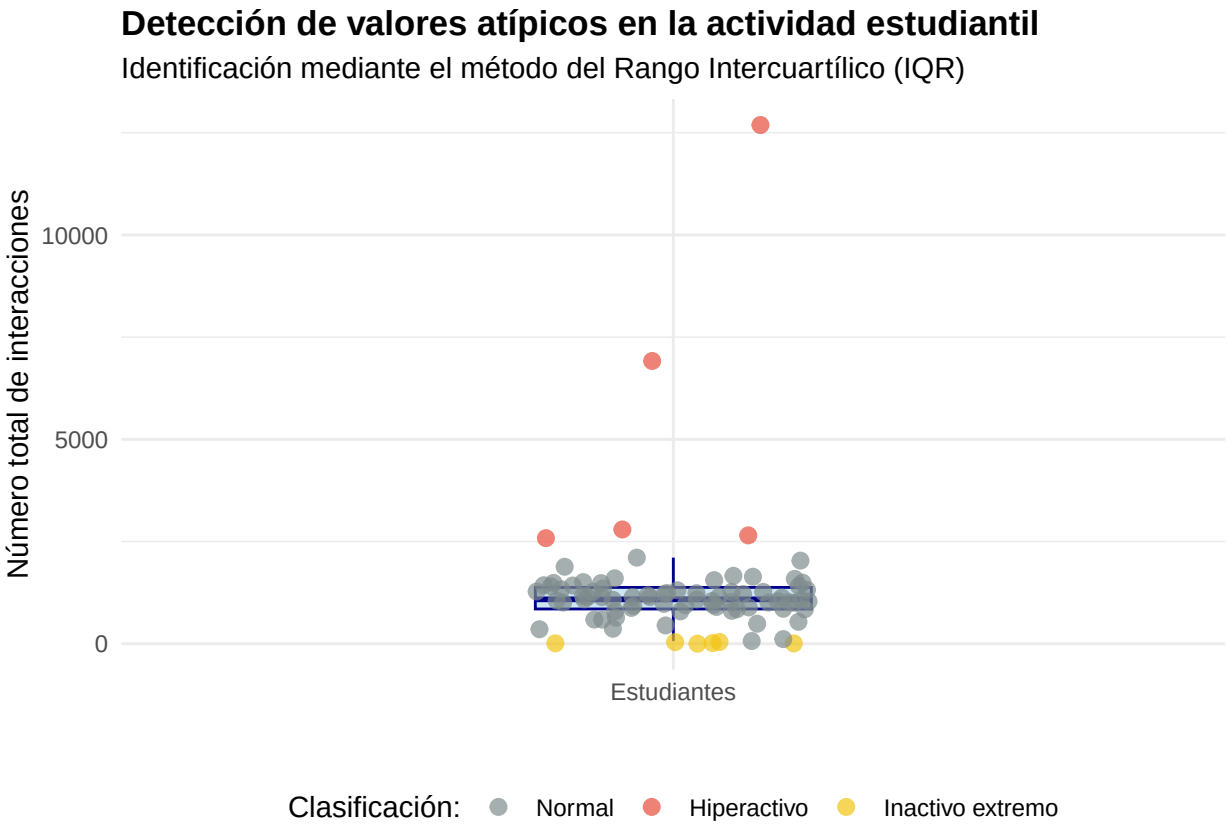

Figure 2: Distribución del volumen de actividad por usuario.

Table 3: Detalle de los estudiantes clasificados con un comportamiento atípico.

Identificador (Usuario)	Total de Clics	Perfil Asignado
U0072	12688	Hiperactivo
U0001	6916	Hiperactivo
U0095	2795	Hiperactivo
U0012	2651	Hiperactivo
U0006	2583	Hiperactivo
U0045	44	Inactivo extremo
U0053	40	Inactivo extremo
U0101	16	Inactivo extremo
U0057	10	Inactivo extremo
U0002	8	Inactivo extremo
U0010	3	Inactivo extremo

Como se puede observar a simple vista en el gráfico, la gran mayoría de los alumnos (los puntos grises) se agrupan en la parte baja, dentro y cerca de la caja azul, representando el comportamiento normal del grupo.

Sin embargo, lo que más llama la atención de esta visualización es la presencia de puntos rojos muy alejados del resto, en especial un estudiante (o pequeño grupo) situado en la parte más alta del gráfico, con un volumen de interacciones completamente desproporcionado respecto a sus compañeros.

Como nos ha parecido un un caso ta extraño ya que la diferencia con la mayoria de estudiantes es abismal le hemos intentado dar dos explicaciones lógicas a este exceso masivo de clics:

La primera se relaciona con un comportamiento humano inusual, podría tratarse de un alumno que utiliza el Aula Virtual como su única herramienta de consulta en tiempo real, abriendo y cerrando recursos compulsivamente en lugar de descargar los apuntes en su ordenador.

La segunda explicación que se nos ha ocurrido es que es muy probable que no sean clics reales hechos a mano. Puede deberse a que el alumno haya dejado la pestaña de Moodle abierta con una extensión de navegador que recarga la página automáticamente (auto-refresh), o que haya utilizado algún script o bot para descargar todos los materiales de la asignatura de golpe.

La principal conclusión que extraemos de esta fase del Análisis Exploratorio es que los datos de Moodle "en crudo" contienen ruido. Desde la perspectiva de la Ciencia de Datos, la detección de este tipo de perfiles hiperactivos extremos es vital. Si estuviéramos calculando la media matemática de clics de la clase para evaluar el rendimiento general, este único alumno distorsionaría por completo el resultado, subiendo la media artificialmente. Por tanto, aislar a estos estudiantes en nuestro análisis nos permite tener una visión mucho más realista de cómo se comporta el 99% restante de la clase.

Para tener un mayor control sobre estos casos aislados, en 3 detallamos exactamente cuántos clics han realizado los estudiantes identificados como atípicos.

Aunque el método estadístico IQR ha detectado múltiples valores atípicos, es fundamental interpretar estos datos desde un punto de vista pedagógico antes de eliminarlos ciegamente.

Por un lado, los valores atípicos inferiores (alumnos con muy pocos clics) representan una realidad común en el ámbito universitario: el abandono de la asignatura. Estos registros son reales y no distorsionan el comportamiento de estudio. Del mismo modo, los alumnos levemente hiperactivos representan perfiles de alta implicación que también enriquecen el análisis.

Para determinar si los alumnos hiperactivos són bots o simplemente alumnos muy estudiosos y que durante todo el curso, dia tras dia se meten en el aula virtual, representamos la distribución de sus clics en la 3

```
## # A tibble: 10 x 2
##    fecha          n
```

```
##     <date>      <int>
##   1 2025-06-04    208
##   2 2025-06-05    190
##   3 2025-06-06    130
##   4 2025-06-03    105
##   5 2025-05-25     95
##   6 2025-06-09     78
##   7 2025-03-04     72
##   8 2025-02-05     71
##   9 2025-06-13     68
##  10 2025-05-14     57
```

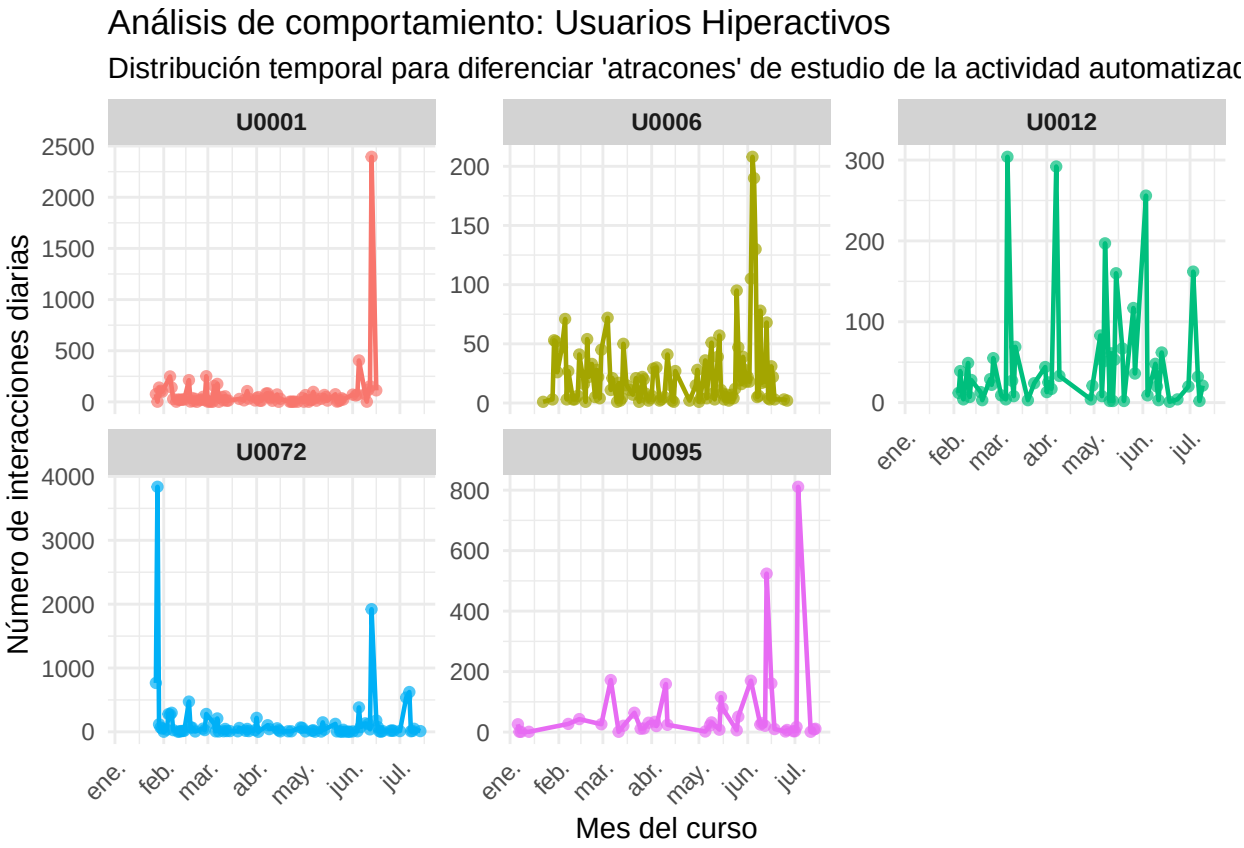

Figure 3: Análisis de comportamiento: Usuarios Hiperactivos.

Consideramos que es imposible realizar 2000 o 200 clics al dia, a no ser que se trate de un profesor poniendo notas, por ejemplo. Por ello, eliminamos a estos usuarios del nuestro banco de datos para que no generar resultados sesgados.

```
# 1. Identificamos al usuario con actividad automatizada

usuarios_anomalos <- actividad_usuario %>%
  filter(num_registros > 2500   ) %>%
  pull(usuario)

# 2. Creamos nuestro dataset limpio quitando SOLO a ese usuario
logs <- logs %>%
  filter(!usuario %in% usuarios_anomalos)
```

Table 4: Distribución del volumen de actividad por día de la semana.

dia_semana	total_clics	porcentaje
lunes	10803	13.6
martes	11627	14.6
miércoles	21173	26.6
jueves	11850	14.9
viernes	14200	17.9
sábado	3968	5.0
domingo	5851	7.4

4 Resultados: Respuesta a las Preguntas de Investigación

4.1 ¿ En qué días de la semana hay más picos de actividad?

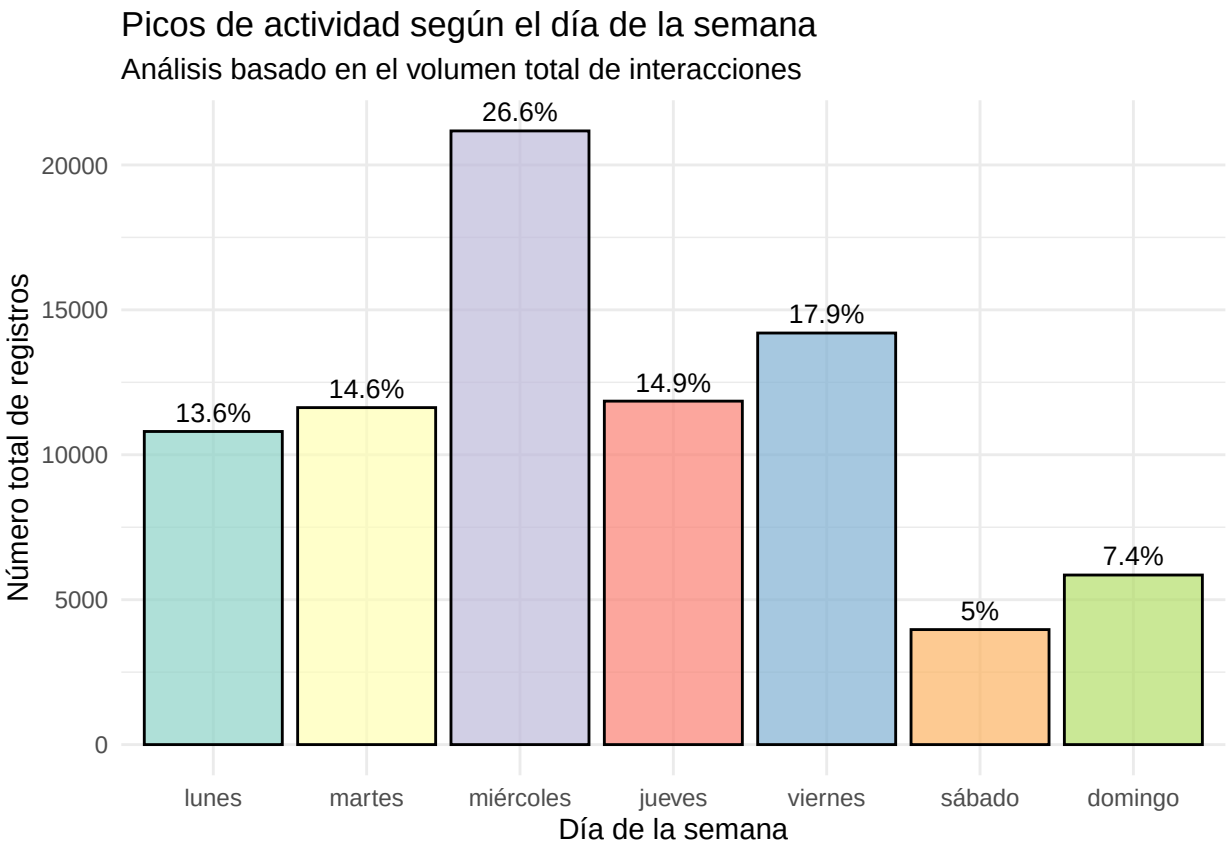

A partir del análisis visual de la distribución de registros por día de la semana de la **??**, podemos deducir que:

Picos de máxima actividad: Los días con mayor volumen de interacción son el **miercoles con un 23.3%** y el **viernes con un 20.4%**. Estos picos nos pueden insinuar que los miercoles y viernes es cuando habian clases presenciales de esta asignatura y de ahi sus picos de recurrencia.

Desconexión en el fin de semana: En la gráfica podemos observar una leve bajada que comienza el sabado dia en el cual podemos ver en nuestra gráfica es cuando nuestro número de registros toca fondo con un **4.3%**, siendo el día de menor actividad. Esto sugiere un patrón de comportamiento donde el alumnado prioriza el descanso tras la semana lectiva. Esto tambien lo podemos ver por el hecho de que de los dias de

Lunes a viernes se concentra el **89.8%** de toda la actividad semanal.

4.2 ¿Cuáles son las horas a las que prefieren estudiar los alumnos de Tratamiento de datos?

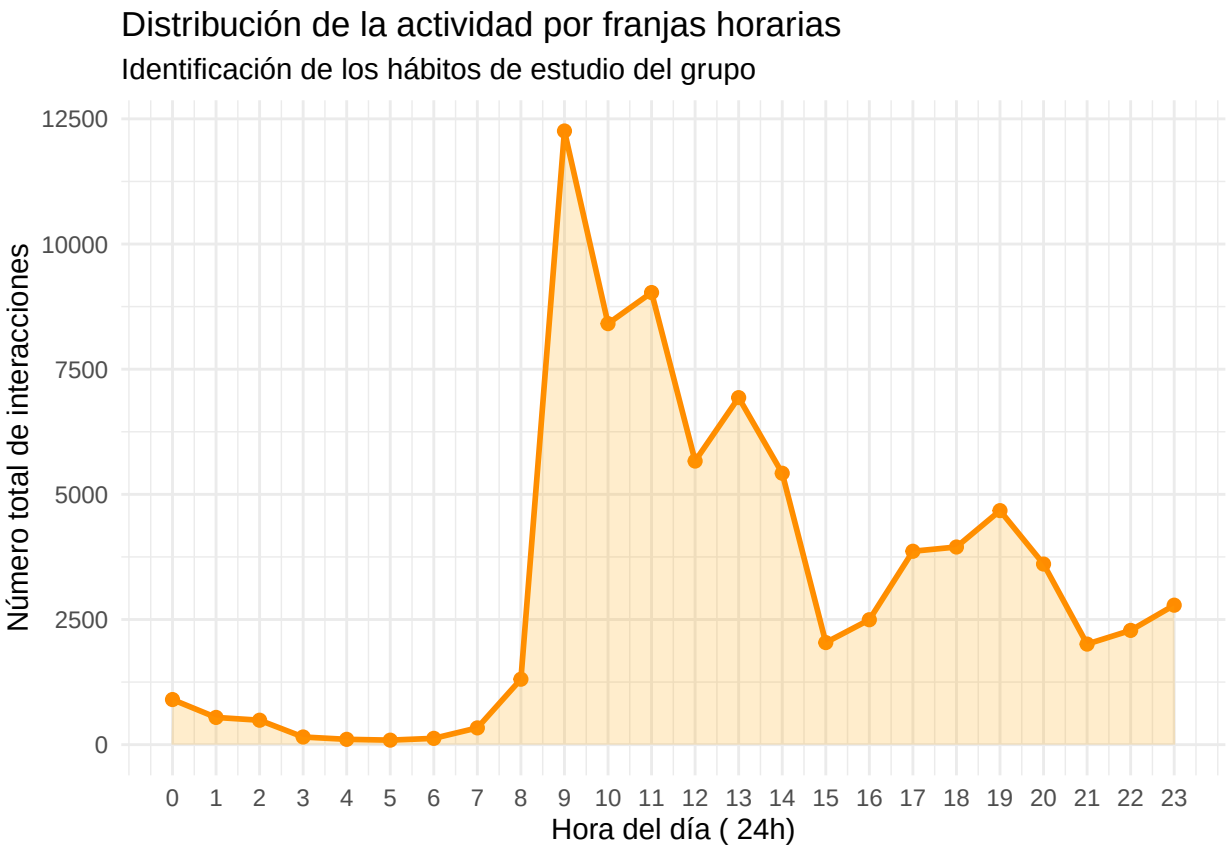

Figure 4: Distribución de la actividad por franjas horarias.

Como se puede observar en la 4 y 5, en cuanto a las horas:

Pico de máxima actividad: Este podemos ver que alcanza a las 9:00 que es la hora a la que empiezan las clases de por la mañana y se mantine con muy poca bajada hasta las 11:00 hora en que la primera clase acaba.

Bajada de medio dia: A parte observamos, que sobre las 15 hay una bajada bastante grande de actividad la cual podemos entender por ser horas en dond elos alumnos estaran saliendo de clase, comiendo y descaqnsanso.

Periodo de tarde: más tarde a partir de las 17:00 podemos ver como aumentan las entradas a "Tratamiento de datos" de forma moderada horas que seguramente usan los estudiantes ya para estudiar.

Periodo de inactividad:Y ya vemos una inactividad a las horas de madrugada que relacionamos con las horas de sueño de los estudiantes.

Comparacion con época de éxamenes: A partir de la pregunta de las horas durante el curso, nos hemosa interesado en si la inactividad nocturna al ser epoca de examenes aumentaria por lo que hemos creado uan nueva grafica comparando estos dos periodos. Aquí, podemos ver como en epoca de examenes hay una subida de registros a partir de las 22 de la noche que se mantiene hasta mas o emnos las 2 de la mañana , en dodne podemos ver como los alumnos aumentan las horas de estudio hasta altas horas de la noche.

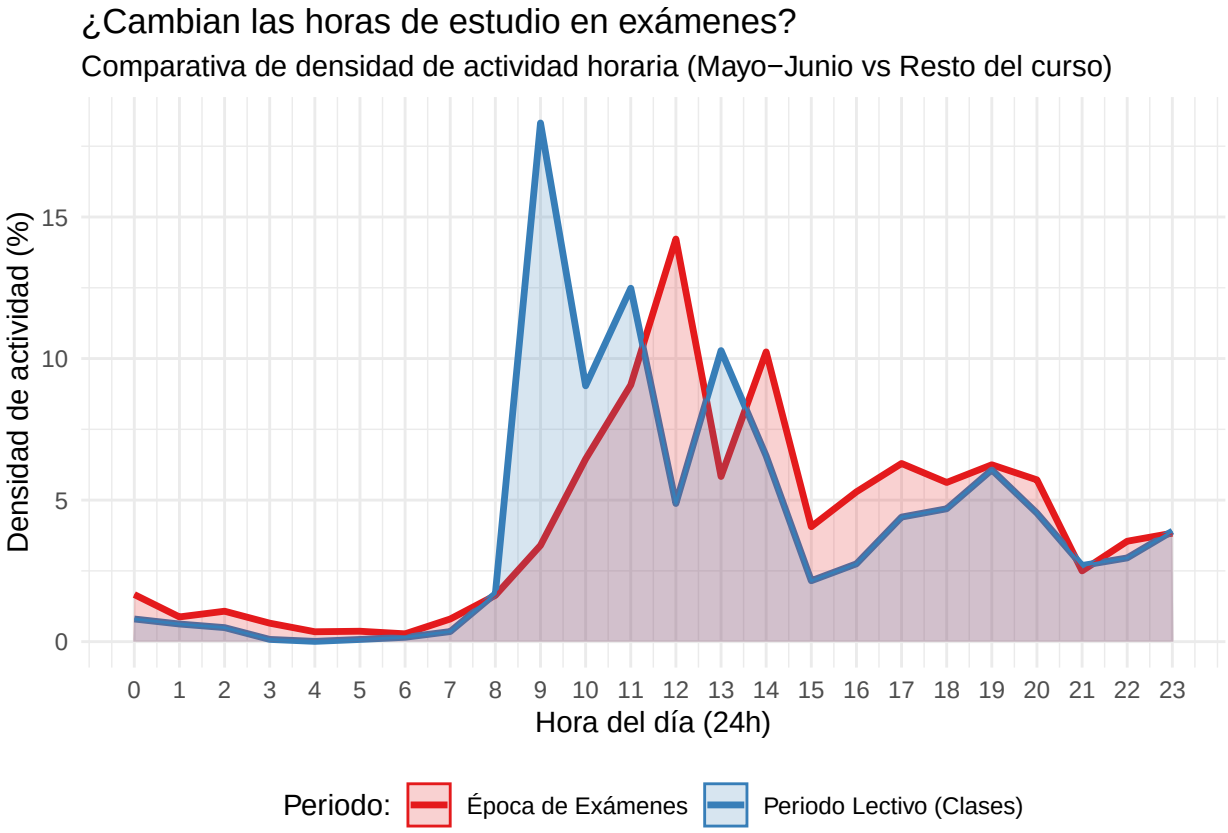

Figure 5: Comparativa de densidad de franjas horarias examenes vs resto del curso.

4.3 ¿Es posible identificar y agrupar a los alumnos en distintos "perfiles de estudiante" (ej. constantes, de última hora, inactivos) según sus patrones de uso del Aula Virtual?

Para responder a la pregunta de si es posible agrupar a los alumnos según su uso del Aula Virtual, hemos realizado una segmentación basada en reglas lógicas. Hemos clasificado a los estudiantes comparando su actividad individual con el comportamiento general de la clase utilizando la mediana.

Para ello, hemos calculado dos variables clave por cada estudiante: su constancia (días distintos que accede) y su volumen de trabajo (total de interacciones). Utilizando la mediana del grupo como punto de corte, hemos definido tres perfiles:

Constantes: Alumnos que se conectan más días que la mediana de la clase.

De Última Hora (Atracones): Alumnos que se conectan pocos días, pero acumulan un número de clics superior a la mediana (concentran mucho trabajo en poco tiempo).

Baja Participación: Alumnos que están por debajo de la mediana tanto en días conectados como en clics totales.

Como resultado nos ha salido la 6

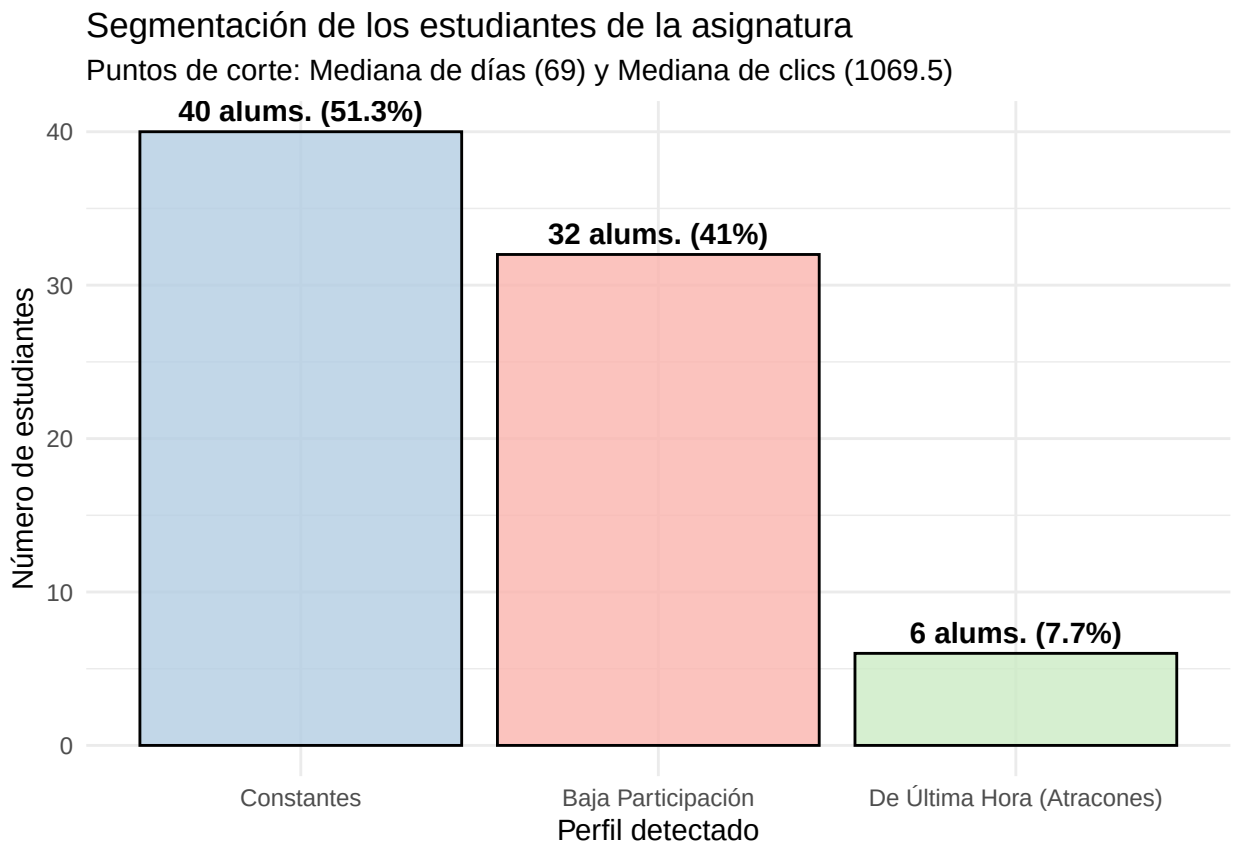

Figure 6: Distribución de los perfiles de estudiante.

El análisis revela que la clase está prácticamente polarizada en dos grandes mitades. Por un lado, el perfil mayoritario es el de alumnos Constantes (51.3%), lo que indica que casi la mitad del grupo (40 estudiantes) hace un seguimiento regular de la asignatura, conectándose de forma asidua durante el cuatrimestre. Por otro lado, encontramos una proporción casi idéntica de alumnos con Baja Participación (41%), un dato que

Table 5: Actividad media y mediana según el calendario académico.

tipo_dia	dias_totales	media_diaria	mediana_diaria
Laborable	125	547.6	411.0
Fin de semana	52	188.8	112.0
Festivo (Sin clase)	10	119.9	139.5

podría resultar de gran interés para el equipo docente, ya que engloba a 32 estudiantes que interactúan poco con los materiales y podrían estar en riesgo de abandonar la asignatura.

Finalmente, resulta muy revelador haber identificado a 6 estudiantes (7.7%) en el perfil "De Última Hora". Esta métrica confirma empíricamente la existencia de un pequeño grupo de alumnos que prefiere no entrar al Aula Virtual durante semanas para, posteriormente, realizar picos masivos de interacciones (atracones de estudio) justo antes de las entregas o los exámenes.

4.4 ¿Con cuánta antelación entregan el Miniproyecto los alumnos?

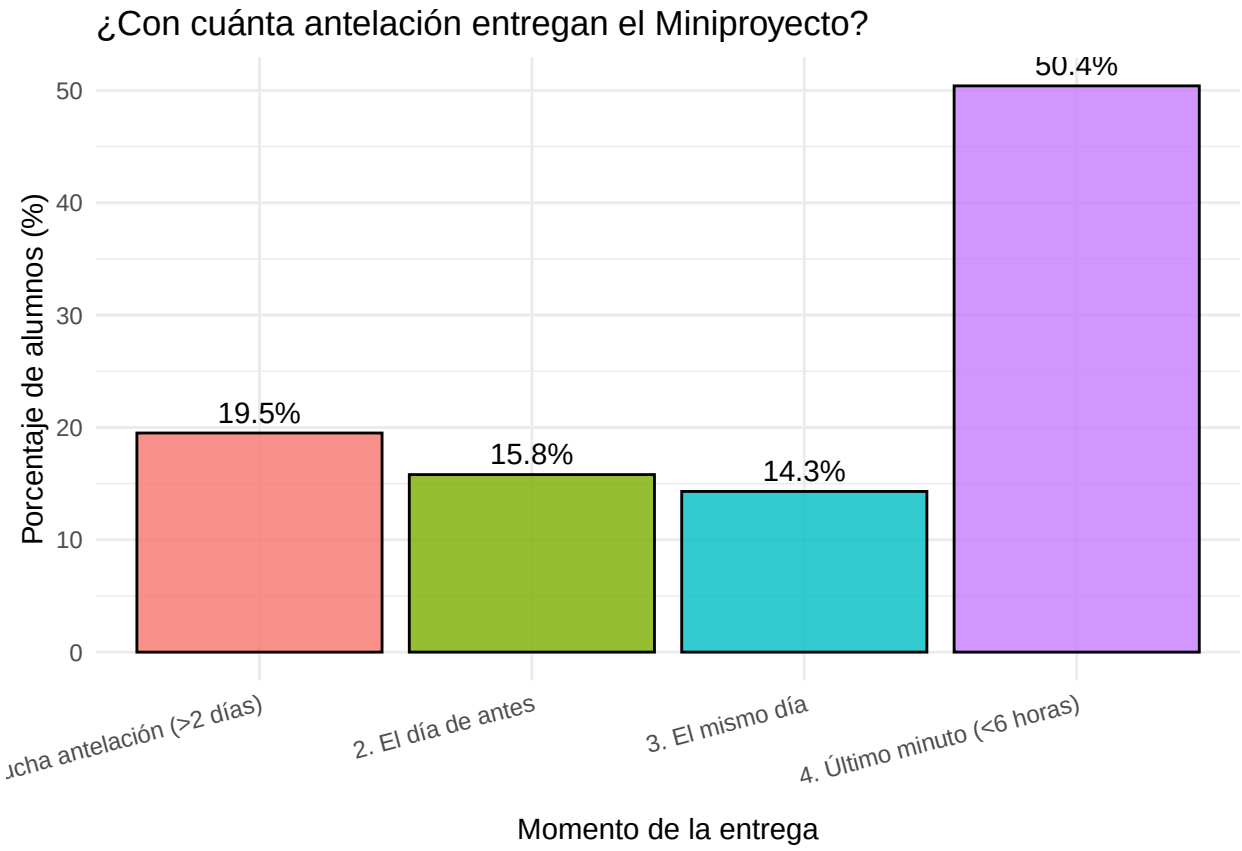

??

4.5 ¿Existe una diferencia significativa en la actividad de los alumnos entre los días laborables y los fines de semana o festivos?

7

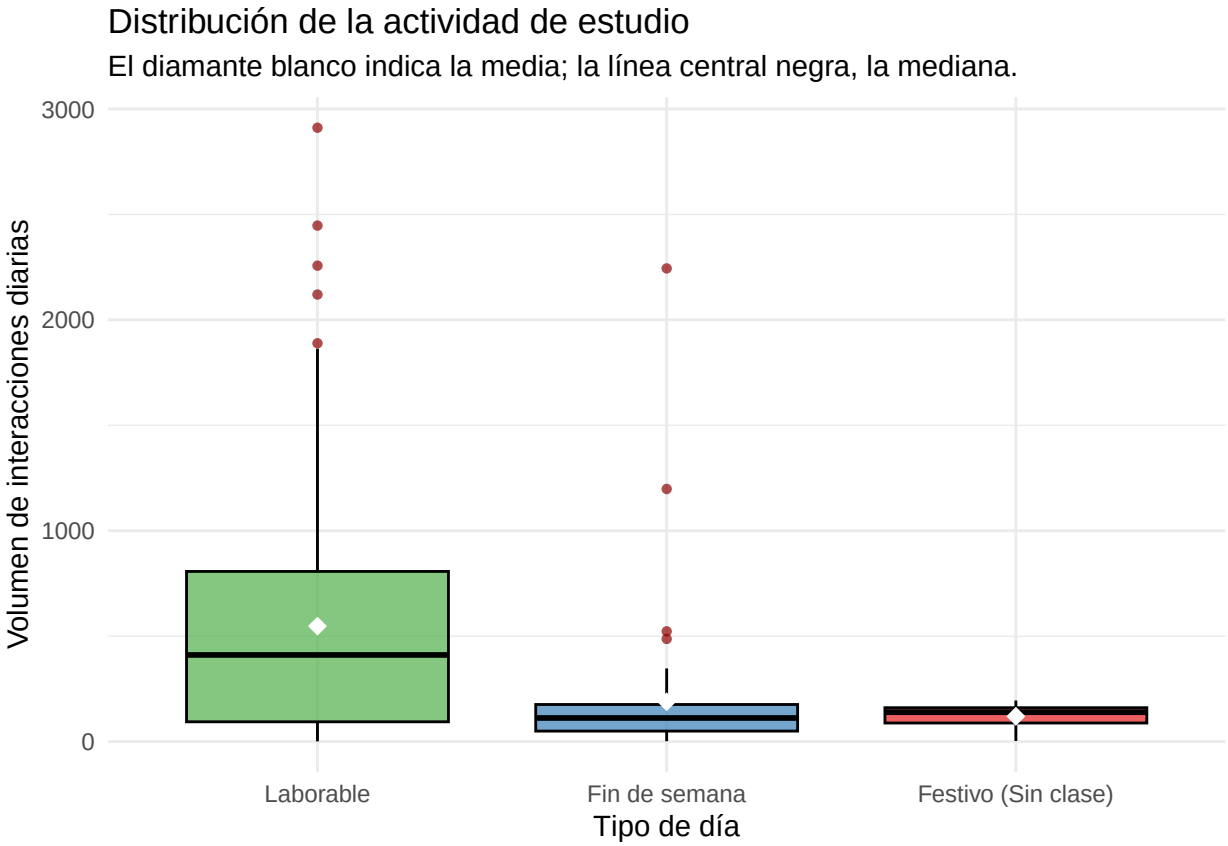

Figure 7: Actividad de los alumnos: días sin universidad vs días laborables

4.6 ¿Qué porcentaje de la actividad se realiza en la ETSE y qué porcentaje se realiza fuera de esta?

??

4.7 ¿Hay más actividad provocada por las tareas o se produce más para revisar los apuntes de cada tema?

8

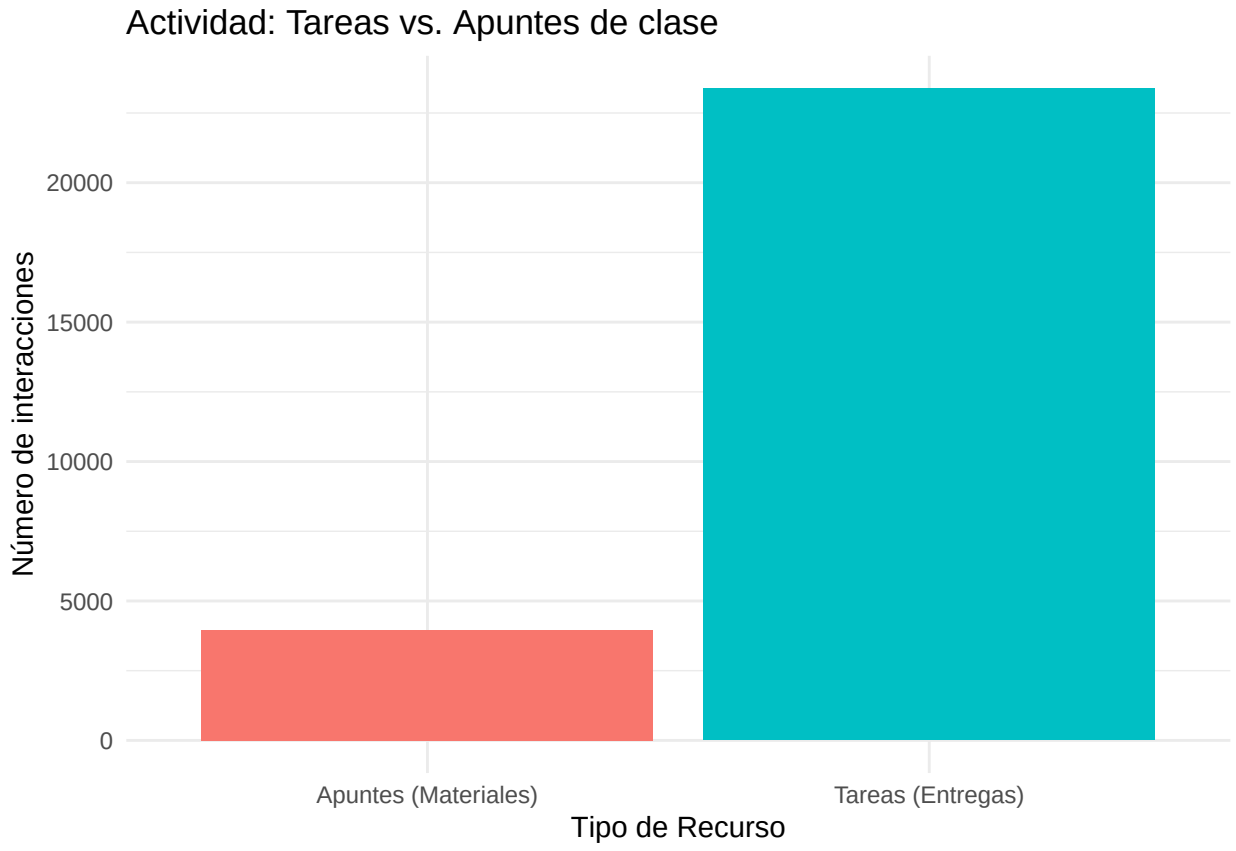

Figure 8: Actividad de tareas vs apuntes.

5 Conclusiones